

PRZEDMIOT: METODY EKSPLORACJI DANYCH

Wnioskowanie z niepełnych danych z wykorzystaniem imputacji kNN

Adam Sokołowski

Etap 1: Projekt implementacji • 08.05.2026

Cel i Zakres Projektu

🎯 Cel Główny

Przygotowanie i implementacja algorytmu **k-Nearest Neighbors** do uzupełniania braków w danych numerycznych oraz rzetelna ocena jego jakości i wydajności.

Zakres Techniczny

- ✓ Architektura modułowa klas i funkcji.
- ✓ Struktury przechowujące maski i odległości.
- ✓ Mapowanie algorytmu na metody programu.
- ✓ Plan testów (RMSE, MAE, wydajność).
- ✓ Analiza złożoności obliczeniowej.

Dokument stanowi opis techniczny rozwiązania przed etapem kodowania.

Wybrane Technologie



Python

Główny język implementacji.
Wybrany ze względu na
natywne wsparcie dla obliczeń
naukowych i łatwość
prototypowania.



NumPy & Pandas

NumPy: Operacje
macierzowe i wektoryzacja.
Pandas: Manipulacja danymi i
raportowanie wyników.



Wizualizacja

Matplotlib: Generowanie
wykresów trendów RMSE,
MAE oraz skalowalności
czasowej algorytmu.

Rdzeń algorytmu kNN zostanie zaimplementowany samodzielnie (bez gotowych rozwiązań scikit-learn).

Planowana Struktura Modułów

Moduł	Odpowiedzialność
data_loader.py	Wczytywanie CSV, selekcja cech, konwersja do macierzy.
preprocessing.py	Normalizacja MinMax, tworzenie masek braków danych.
knn_imputer.py	Implementacja logiki kNN (odległości, sąsiedztwo).
metrics.py	Metryki błędu RMSE/MAE i pomiar czasu działania.
experiments.py	Uruchamianie serii testów dla różnych parametrów k.
main.py	Punkt wejścia i konfiguracja eksperymentów.

Najważniejsze Klasy

DatasetLoader

Metody `load_csv` i `to_numpy`.
Wynik: macierz X o rozmiarze $n \times m$.


Preprocessor

Normalizacja do $[0, 1]$
(kluczowe dla kNN) oraz
funkcja
`inject_missing_values` do
testów.

KNNImputer

Pola: `k`, `weights`
(uniform/distance). Metoda
`fit_transform` sterująca
procesem.

Sekwencja Pracy Algorytmu



Szczegóły Metod Imputacji

Warianty Agregacji

Uniform: Zwykła średnia arytmetyczna k-sąsiadów.

Distance: Średnia ważona odwrotnością odległości.

$$V = \frac{\sum (w_i \cdot v_i)}{\sum w_i}$$

Mechanizmy Zabezpieczające

Małe odległości: Stała epsilon zapobiega dzieleniu przez zero.

Fallback: Jeśli brak sąsiadów z daną cechą, użyta zostanie średnia/mediana kolumny (`_fallback_column_value`).

Wspólne cechy: Odległość liczona tylko po znanych atrybutach obu rekordów.

Analiza Złożoności

$$O(r \cdot n \cdot m)$$

Złożoność Czasowa

Parametry wejściowe:

R r : liczba brakujących komórek

N n : całkowita liczba rekordów

M m : liczba cech (atrybutów)

Dominującym kosztem jest obliczanie odległości dla każdej brakującej wartości. Pamięć: **$O(n \cdot m)$** dla macierzy danych i maski.

Zbiory Danych do Eksperymentów

Gene Expression

Bardzo duża liczba atrybutów (cech). Pozwoli sprawdzić wpływ parametru m na wydajność.

Adult Income

Duża liczba rekordów (wierszy). Kluczowy zbiór do testu skalowalności względem parametru n .

Breast Cancer

Dane medyczne z naturalnymi zależnościami. Służy do weryfikacji jakości (RMSE) imputacji.

W zbiorach kompletnych braki zostaną wygenerowane sztucznie (MCAR: 5%, 15%, 30%).

| Strategia Testów

1. Poprawność i Jakość

-  RMSE i MAE względem wartości oryginalnych.
-  Testy dla różnych wartości k (3, 5, 7, 11).
-  Walidacja dla różnych ziaren losowych (seeds).

2. Wydajność i Benchmarking

-  Czas działania vs wielkość zbioru.
-  Porównanie z imputacją średnią i medianą.
-  Porównanie z implementacją scikit-learn.